

基于 SAM2 先验引导与空频域对齐的目标检测算法

引言

红外-可见光双模态目标检测技术通过融合多源传感器的互补信息，显著提升了视觉感知系统在弱光、遮挡、恶劣天气等受限场景下的鲁棒性。然而，现有的多数主流方法往往采用直接的并行特征提取与空间域拼接融合范式，较少显式处理两种模态在物理成像机理、空间映射关系以及下游任务需求上的差异，导致模型陷入严重的跨模态特征不对齐。具体表现在以下三个阶段：首先，在特征提取阶段，模态特征不对齐。RGB 图像侧重色彩与纹理，而 IR 图像反映热辐射分布，两者物理属性截然不同。将两者送入未加区分的特征提取器，极易引发模态竞争，进而造成语义混淆和目标特征淹没。其次，在特征融合阶段，空间几何不对齐。受限于双相机的物理基线距离、焦距差异以及非理想配准，RGB 与 IR 图像中的同一目标在像素级空间上往往存在几何错位。传统的空间域特征拼接会放大这种错位，造成融合后的目标边缘严重模糊或产生重影。最后，在特征解码阶段，频域特征与下游任务的不对齐。在目标检测任务中，分类分支具有平移不变性通常偏好平滑且具有强语义的低频信息，而回归分支具有平移敏感性则依赖于锐利的边缘和纹理等高频信息。这种任务诉求的差异与融合噪声的叠加，导致耦合的共享特征难以同时满足检测头的分类和回归的双重需求。

为了解决上述特征不对齐难题，本章节提出了一种基于 SAM2 先验引导与空频域对齐的目标检测算法。本章的核心贡献具体可概括为以下三个方面：首先，提出 SAM2 先验引导的细粒度解耦路由编码器，以缓解模态特征不对齐问题。SAM2^[46]是一种庞大且效果好的目标分割模型，为了平衡效果与效率，只引入冻结的 SAM 2 Image Encoder 作为教师网络，将 RGB 与 IR 图像先融合映射为统一先验输入，再提取边界轮廓先验。同时，设计了通道级（Channel-Level）与网格级（Grid-Level）双路细粒度分化模块，在轻量级 MoE（混合专

家)路由器的动态分配下,增强弱目标和密集目标的可分性,在特征提取阶段削减模态竞争。其次,提出聚焦-发散动态空间对齐机制,解决空间几何不对齐问题。针对传感器视差引起的像素级错位,本章摒弃了基于固定感受野的对齐范式,构建了一种基于多尺度空洞卷积的聚焦-发散模块。该模块通过计算不同位置的聚焦度(捕捉局部高保真细节)与发散度(跨越长距离感知视差),自适应地生成亚像素级的动态偏移量与空间调制掩码。通过建立基于距离反比的重采样聚合机制,网络能够将发生偏移的双模态特征精细校正至统一的空间坐标系内,从而有效弥补融合特征的空间视差,为后续的高精度定位奠定了基础。最后,提出任务解耦的启发式频率选择解码器,解决频率特征与任务不对齐问题。为了消除融合特征中的高频插值伪影并满足不同检测头的需求,本章将解码过程转换至频域进行。通过提取全局频谱统计量作为启发式信息,网络动态生成任务专属的频率掩码,为分类分支滤除高频噪声以保留纯净语义,为回归分支保留锐利的高频边缘以实现精准定位。该设计实现了噪声过滤,也缩小了跨域特征与下游检测任务之间的差异。

网络结构

本章算法的总体结构如下图,总体架构是一种全新的三重动态对齐网络。由 SAM2 先验引导的细粒度解耦路由编码器模块(SAM2-Prior-DrivenDecoupledRoutingEncoder,SPD-DRE)、聚焦-发散动态空间对齐模块(Focus-DivergenceDynamicSpatialAlignment,F-DDSA)以及启发式频域选择解码器模块(HeuristicFrequencySelectionDecoder,HFSD)三个核心阶段和损失函数构成,形成了一个紧密联动的端到端框架。




图 3.1 基于 SAM2 先验引导与空频域对齐的跨模态目标检测算法框架

首先，在特征提取阶段，RGB 与 IR 图像分别输入双流 ResNet 骨干网络。冻结的 SAM 2 Image Encoder 教师分支仅在训练阶段参与先验蒸馏。配准后的 RGB 与 IR 图像先进行融合映射，再作为统一先验输入送入教师分支，以提取边界轮廓先验；推理阶段该教师分支被完全卸载。该先验经由学生侧先验代理与轻量级 MoE 路由器蒸馏到 SPD-DRE 中。通道-网格解耦编码器将特征沿通道级与网格级双向分化并交由专属专家处理，从源头实现了模态属性与空间细节的彻底解耦。其次，在跨模态融合阶段，为克服传感器物理视差带来的空间错位，提取的多尺度特征进入聚焦-发散动态对齐融合模块。该模块内嵌于 FPN 与 PAN 构成的双向特征金字塔中，利用各个特征点的聚焦与发散作用对未对齐特征进行亚像素级的自适应空间校正与重采样，完成了高精度的空间几何对齐。最后，在任务解码阶段，对齐后的特征被送入启发式频率选择解码器。网络将多尺度空间特征转换至频域，动态生成两组任务解耦的频率掩码：低频分支 $L(u,v)$ 滤除模态噪声以保障分类语义的纯净，高频分支 $H(u,v)$ 保留锐利跳变以支撑边界框的精准回归。经过频空逆变换与特征重构后，最终由检测头输出高精度的目标定位与类别预测结果。整个架构通过三层体系架构递进地消解了跨模态检测中特征在提取、融合、和解码中的显著差异。

SAM2 先验引导的细粒度解耦路由编码器模块




图 3.2 基于 SAM2 先验引导的细粒度解耦路由编码器模块框图

本模块在经过由 Norm-Conv-GELU-Norm 构成的残差块的初步的特征提取后，将输入特征 $X \in \mathbb{R}^{B \times C \times H \times W}$ 沿两个正交方向进行分化提取，分别是网格级（Grid）分割和通道级（Channel）分割。在深度卷积特征中，空间网格主要承载局部边界结构、区域形状与邻域连续性。

网格级分割侧重于捕捉多尺度的局部边界变化与区域结构差异。网络将特征图在空间维度划分为 N 个不重叠的局部网格，将其转换为序列化张量：

$$X_{grid} = \text{Unfold}(X) \in \mathbb{R}^{B \times N \times C \times P \times P} \quad (1.1)$$

其中， P 为网格的空间尺寸。这些网格特征将被优先分配给空间专家，空间专家内部采用 $3 \times 3, 5 \times 5, 7 \times 7$ 的多尺度深度可分离卷积，以动态感受野精准锁定目标的物理边缘。

通道级划分侧重于剥离跨模态的全局风格与频率差异。网络保持特征的空间分辨率不变，沿通道维度 C 将特征均分为 G 组：

$$X_{\text{channel}} = \text{Split}(X, \text{dim} = C) \in \mathbb{R}^{B \times G \times \frac{C}{G} \times H \times W} \quad (1.2)$$

通道分组特征将被优先送入频率专家，利用二维快速傅里叶变换和全局平均池化在频域内滤除模态噪声并强化核心语义。

虽然上述解耦机制明确了特征的分工，但轻量级的混合专家（MoE）网络在面对复杂场景时，其内部路由器往往难以做出最优的专家分配决策。本章采用冻结的 SAM2 Image Encoder 作为教师网络。在训练阶段，先将配准后的 RGB 与 IR 图像进行融合映射，构造统一先验输入再送入冻结的 SAM2 Image Encoder，以提取边界轮廓先验特征 S_{sam} 。

同时，在学生网络端，为了在极低计算开销下实现对 SAM 2 高维特征的精准拟合，本节参考了轻量级知识蒸馏范式，对先验代理生成器（SAM2-Proxy Generator）的内部架构进行了专门设计。该生成器首先拼接双模态原始图像 $I_{concat} = [I_{rgb}, I_{ir}]$ 为输入。为了在控制计算复杂度的前提下从像素空间映射至高维边界空间，代理生成器采用了轻量级的全卷积架构。其前端由步长为 2 的轻量级卷积层构成，用于初步的特征降维与感受野扩充。其深层则堆叠了深度可分离残差块，以极低的计算开销捕捉双模态图像中的局部空间梯度与几何突变。此外，为抑制平滑背景区域的冗余激活，生成器末端引入了轻量级空间注意力机制，通过沿通道维度进行最大池化与平均池化以提取显著边界响应，最终输出学生代理特征 $S_{student}$ 。其核心数学表达为：

$$F_{mid} = \mathcal{F}_{IRB}(\text{Stem}([I_{rgb}, I_{ir}])) \quad (1.3)$$

$$S_{student} = F_{mid} \odot \sigma(\text{Conv}_{7 \times 7}([\text{MaxPool}(F_{mid}), \text{AvgPool}(F_{mid})])) \quad (1.4)$$

式中， $\text{Stem}(\cdot)$ 表示前端降采样操作， $\mathcal{F}_{IRB}(\cdot)$ 表示深度可分离特征提取网络。网络实现了直接从原始图像到边界特征的端到端映射设计，在数学上保证了蒸馏输入的一致性。

为了将先验知识高效注入到解耦后的特征中，本章设计了一种基于仿射调制的专家路由机制。轻量级路由器以学生网络独立生成的先验 $S_{student}$ 为引导，预测各位专家的分配权重，还动态生成尺度缩放因子 γ 与平移因子 β 。其专家网络分为频率专家和空间专家，具体

参考如图 3.2 右侧部分。尺度缩放因子 γ 与平移因子 β ，其具体实现为先让特征 $S_{student}$ 执行全局平均池化与两层多层感知机，提取特定专家的全局统计描述向量。随后，将该向量经 Sigmoid 激活后，广播至与输入特征 X_k 相匹配的空间维度。其路由机制对于任意输入特征 X_k ，其经过第 i 个专家网络 $Expert_i$ 处理后的特征图，将接受学生先验的仿射调制为：

$$\tilde{Y}_{k,i} = Expert_i(X_k) \odot \gamma_i(S_{student}) + \beta_i(S_{student}) \quad (1.5)$$

在训练阶段，网络通过引入特征蒸馏损失，迫使学生网络生成的 $S_{student}$ 不断逼近教师特征 S_{sam} 。而在推理阶段，SAM2 编码器分支将被移除，学生网络凭借已习得的知识独立生成 $S_{student}$ 并完成特征调制。该机制既带来了 SAM2 大模型的特征先验，又保证了多模态检测器的推理速度，实现了零成本先验注入。式中， $\odot$ 表示逐元素相乘。缩放因子 γ_i 负责调整特征激活的对比度，凸显关键轮廓。平移因子 β_i 负责补充可能丢失的背景基准值。这种乘加结合的方式有效保证了特征表征的完整性。最后，网络根据 Router 同步输出的门控权重 $w_i \in (0,1)$ ，对所有经过仿射调制后的专家输出进行加权聚合，并重构（Reshape）回原始维度：

$$F_{out} = \text{Reshape} \left(\sum_{i=1}^K w_i (P_{stu}) \cdot \tilde{Y}_{k,i} \right) \quad (1.6)$$

通过这一机制，网络不仅实现了通道与网格维度的解耦，更在无推理成本的 SAM2 隐式先验调制下，完成了高质量的跨模态特征表征，为后续的空间对齐与融合奠定了坚实的基础。

聚焦-发散动态空间对齐模块




图 3.3 聚焦-发散动态空间对齐模块框图

跨模态融合面临着第二个核心痛点：空间几何不对齐。受限于双相机物理位置的不同以及非理想的配准，同一目标在 RGB 和 IR 特征图上不可避免地存在像素级位移。为此，本节提出了一种聚焦-发散动态空间对齐机制。该机制构建了一个基于距离反比加权的动态重采样场，通过局部聚焦与全局发散机制，纠正错位的亚像素级别的特征。

为了让网络能够自适应地感知当前特征的错位程度，首先需要计算图像空间中每个像素点的聚焦度（Focus）与发散度（Divergence）。聚焦度代表特征已对齐，只需关注局部。而发散度代表特征存在显著错位，需要扩大感受野去寻找匹配特征。具体而言，如图 3.3，网络首先将输入的可见光特征 F_{rgb} 与红外特征 F_{ir} 在通道维度进行拼接，随后将其送入两个感受野不同的并行分支即聚焦分支和发散分支。聚焦分支采用标准的 3×3 卷积，用于捕捉局部细节与保真度；发散分支采用膨胀率为 2 的 3×3 空洞卷积，利用更大的感受野跨越空间距离去捕捉由于视差导致的长距离位移特征。两个分支的输出拼接后，经过逐点卷积与平滑，生成聚焦度特征图 F_{foc} 与发散度特征图 F_{div} ，其数学表达如下：

$$F_{foc}, F_{div} = C_{3 \times 3} \left(C_{1 \times 1} \left([C_{3 \times 3}(F_{rgb}, F_{ir}), C_{3 \times 3}^{d=2}(F_{rgb}, F_{ir})] \right) \right) \quad (1.7)$$

式中, $[\cdot, \cdot]$ 表示通道拼接操作, $Ck \times k$ 表示核大小为 k 的卷积层, $C^{d=2}$ 表示空洞卷积。生成的 F_{foc} 和 F_{div} 将作为后续像素重采样的动态引导图。

获取聚焦与发散强度后, 本节设计了一种类似引力透镜的动态对齐函数 $\mathcal{FA}(\cdot)$ 。为了提升对齐过程的灵活性与多目标感知能力, 借鉴多头注意力机制的思想, 将特征图与引导图切分为 n 个组 (Groups) 进行独立对齐, 最后再重组平滑:

$$F'_{rgb} = C_{3 \times 3}([\mathcal{FA}(F_{rgb}^1, F_{foc}^1, F_{div}^1), \dots, \mathcal{FA}(F_{rgb}^n, F_{foc}^n, F_{div}^n)]) \quad (1.8)$$

红外特征 F'_{ir} 的重组过程与可见光特征一致:

$$F'_{ir} = C_{3 \times 3}([\mathcal{FA}(F_{ir}^1, F_{foc}^1, F_{div}^1), \dots, \mathcal{FA}(F_{ir}^n, F_{foc}^n, F_{div}^n)]) \quad (1.9)$$

对齐函数 $\mathcal{FA}(\cdot)$ 的核心在于动态加权聚合。对于目标像素位置 (w, h) , 其聚合周围邻域像素 (w', h') 的计算公式如下:

$$\mathcal{FA}(w, h) = \sum_{(w', h') \in \Omega} F(w', h') \cdot \underbrace{\left(\frac{\alpha F_{foc}(w, h)}{1 + \Delta d^2} + (1 - \alpha) F_{div}(w, h) \right)}_{W_{dign}} \quad (1.10)$$

式中, $\Delta d^2 = (w - w')^2 + (h - h')^2$ 为目标像素与邻域像素的空间欧氏距离平方。项 $\frac{1}{1 + \Delta d^2}$ 构建了距离反比加权机制, 即距离越近, 影响越大, 保证了特征的局部连续性。更关键的是其中的平衡门控因子 α , 其通过对聚焦度和发散度进行 Softmax 归一化求得:

$$\alpha = \frac{e^{F_{foc}}}{e^{F_{foc}} + e^{F_{div}}} \quad (1.11)$$

当图像区域未发生错位时, 聚焦度 F_{foc} 占主导, $\alpha \rightarrow 1$, 发散项被抑制, 网络在距离反比惩罚的约束下收缩感受野, 以保持边缘锐利。当局部存在显著视差错位时, 发散度 F_{div} 激增, $\alpha \rightarrow 0$, 发散项主导全局, 网络自动解除空间距离惩罚, 发散项主导全局。这种动态解除距离限制的机制, 使得模块既能保持未错位区域的清晰度, 又能精准修复大尺度错位区域的几何偏差。

经过空间重采样后，虽然 RGB 与 IR 特征实现了几何维度的对齐，但在重采样过程中不可避免地会产生插值伪影，且红外图像本身固有的热背景噪声依然存在。因此，在最终融合前，本节引入了通道注意力调制模块进行特征融合。首先，对齐后的 F'_{rgb} 与 F'_{ir} 经过全局平均池化提取全局上下文向量，拼接后输入由 MLP 构成的共享网络，计算出两组模态自适应的调制权重：

$$v'_{rgb}, v'_{ir} = \text{Tanh}(W_2 \cdot \sigma(W_1 \cdot [GAP(F'_{rgb}), GAP(F'_{ir})]) + b) \quad (1.12)$$

式中， σ 为 Sigmoid 激活函数， W_1, W_2 为全连接层权重。值得注意的是，这里最终采用Tanh 激活函数将权重 v' 映射至 $[-1,1]$ 区间。最终的跨模态特征融合公式如下：

$$F_{align} = C_{3 \times 3}((1 + v'_{rgb}) \odot F'_{rgb} \oplus (1 + v'_{ir}) \odot F'_{ir}) \quad (1.13)$$

其中， $\odot$ 表示通道级相乘， $\oplus$ 表示逐元素相加。由于 $v' \in [-1,1]$ ，调制系数 $(1 + v')$ 的取值范围为 $[0,2]$ 。当系数 > 1 时，这种残差缩放机制使得网络能够动态放大对齐良好的高优特征，同时当系数 < 1 抑制重采样伪影与模态噪声，最终输出平滑且精准对齐的融合特征 F_{align} 。

启发式频率选择解码器模块




图 3.4 启发式频域选择解码器模块框图

经过多尺度特征金字塔处理后，网络虽然获得了深层特征，但在跨模态亚像素重采样与特征拼接的插值过程中，不可避免地引入了插值伪影与冗余的背景热噪声。此外，在目标检测任务中，分类分支偏好于平滑且具有全局感受野的低频信息，而定位回归分支则高度依赖于真实物理边界的高频跳变。传统的空间域卷积操作往往难以将真实物体边界与高频噪声进行有效剥离。为此，本节从频谱解耦与动态门控的思想出发，设计了启发式频率选择解码器。模块能够根据全局统计特性动态生成频率掩码，对高维特征进行自适应过滤，从而极大地缓解特征域与任务域之间的特征需求冲突。

如图 3.4 所示，为了在频域内分离图像的主干特征与噪声，首先需要将输入的多尺度空间特征转换至频域。经过层归一化后，特征表示为 $M \in \mathbb{R}^{B \times C \times H \times W}$ ，网络对其应用二维快速傅里叶变换：

$$M(u, v) = \mathcal{F}\beta\{X\} = \sum_{x=0}^{H-1} \sum_{y=0}^{W-1} M(x, y) \cdot e^{-j2\pi(\frac{ux}{H} + \frac{vy}{W})} \quad (1.14)$$

式中 $F \in \mathbb{C}^{B \times C \times H \times W}$ 为变换后得到的复数频域特征， (u, v) 为频域空间坐标， $\mathcal{F}\beta \cdot$ 表示二维 FFT 算子。频域复数特征可解耦为幅度谱与相位谱两部分，其中幅度谱表征不同频率分量的能量分布，是频率选择的核心依据；相位谱保留特征的空间结构信息，在变换过程中保持不变以避免空间语义丢失。二者的计算公式为：

$$A(u, v) = |M(u, v)| = \sqrt{\text{Re}\{M(u, v)\}^2 + \text{Im}\{M(u, v)\}^2} \quad (1.15)$$

$$P(u, v) = \angle M(u, v) = \arctan\left(\frac{\text{Im}M(u, v)}{\text{Re}M(u, v)}\right) \quad (1.16)$$

式中 $R\{\cdot\}$ 与 $Im\{\cdot\}$ 分别为取复数实部与虚部的操作， $A \in \mathbb{R}^{B \times C \times H \times W}$ 为幅度谱， $P \in \mathbb{R}^{B \times C \times H \times W}$ 为相位谱。

在进行频率过滤之前，网络需要感知当前场景的整体噪声水平与模态分布状态。如图 3.4 左侧分支所示，提取启发式特征的过程并不在庞大的频域张量上直接进行，而是对空间特征施加轻量级的统计提取。

特征依次经过卷积层、SiReLU 激活函数以及全局池化操作，压缩空间维度以捕获通道级的全局上下文，最后由多层感知机输出启发式特征向量 S ：

$$S = \text{MLP}(\text{Pooling}(\sigma(\text{Conv}(\text{Norm}(M)))))) \quad (1.17)$$

该向量 S 表示了当前图像的宏观统计特性，将作为后续门控网络动态分配专家的核心依据。与传统采用固定高通或者低通滤波器的频域方法不同，本模块设计了由3组可学习专家（LearnableExperts）组成的动态频率选择网络。每一组专家均包含一个低通专家和一个高通专家，它们分别在频域空间 (u, v) 上生成连续且可学习的频率掩码 $L_i(u, v)$ 和 $H_i(u, v)$ 。这些频域函数并非采用固定滤波核，而是以高斯滤波器为基础，通过参数化编码频率特征和自适应权重调制的方式生成，能够根据检测任务的目标分布自动学习最优截止频率与频率响应形态，其构建流程与数学表达如下：

首先是频率坐标的参数化编码，设频域空间的坐标为 (u, v) ，其中 $u \in [0, H-1]$ 、 $v \in [0, W-1]$ ， H, W 为特征图的频域维度，首先对频率坐标进行归一化与特征编码，得到可学习的坐标参数张量。首先将频域坐标归一化至 $[-1, 1]$ 区间，消除维度尺度差异：

$$\begin{cases} \tilde{u} = \frac{u - \frac{H}{2}}{\frac{H}{2}} \\ \tilde{v} = \frac{v - \frac{W}{2}}{\frac{W}{2}} \end{cases} \quad (1.18)$$

然后通过轻量级 MLP 对归一化坐标进行非线性编码， $u_i, v_i \in \mathbb{R}^D$ 为编码后的 D 维坐标特征向量，其中 D 为隐藏层维度，本文中设置为 16：

$$\begin{cases} u_i = \text{MLP}_u(\tilde{u}) \\ v_i = \text{MLP}_v(\tilde{v}) \end{cases} \quad (1.19)$$

h_i 、 l_i 为第 i 组专家的可学习权重张量，分别编码高通/低通核的基础频率响应特性：

$$\begin{cases} h_i = \text{Param}_h^{(i)} \\ l_i = \text{Param}_l^{(i)} \end{cases} \quad (1.20)$$

高通频率响应函数 $H_i(u, v)$ 的生成结合编码后的坐标特征与可学习权重，通过逐元素加权与非线性激活生成高通核的频率响应，公式为：

$$H'_i(u_1, v_1) = h_i \odot (u_i \oplus v_i) \quad (1.21)$$

式中 $\oplus$ 为特征拼接操作， $\odot$ 为哈达玛积，通过可学习权重 h_i 对坐标特征进行调制，捕捉频率坐标与高通响应的关联；接着进行映射：

$$H_i(u, v) = \sigma(\text{MLP}_H(H'_i(u, v))) \cdot \left(1 - G\left(\sqrt{\tilde{u}^2 + \tilde{v}^2}; \mu_h^{(i)}, \sigma_h^{(i)}\right)\right) \quad (1.22)$$

式中 MLP_H 为高通专用的非线性映射网络，输出经 Sigmoid 激活 $\sigma(\cdot)$ 归一化至 $[0, 1]$ ； $G\left(\cdot; \mu_h^{(i)}, \sigma_h^{(i)}\right)$ 为可学习高斯核， $\mu_h^{(i)}$ （截止频率）、 $\sigma_h^{(i)}$ （带宽）为第 i 组高通专家的可学习参数； $1 - G(\cdot)$ 保证核函数在低频区域响应趋近于 0、高频区域响应趋近于 1，符合高通滤波的频率特性。

低通频率响应函数 $L_i(u, v)$ 的构建逻辑与高通对称，通过可学习权重调制坐标特征后，结合高斯核实现低频增强、高频抑制，首先通过低通可学习权重 l_i 调制坐标特征，编码低通响应的坐标依赖关系：

$$L'_i(u_1, v_1) = l_i \odot (u_i \oplus v_i) \quad (1.23)$$

接着进行低通滤波器映射：

$$L_i(u, v) = \sigma(\text{MLP}_L(L'_i(u, v))) \cdot G\left(\sqrt{\tilde{u}^2 + \tilde{v}^2}; \mu_l^{(i)}, \sigma_l^{(i)}\right) \quad (1.24)$$

其中 MLP_L 为低通专用非线性映射网络，输出经 Sigmoid 激活归一化； $G(\cdot; \mu_l^{(i)}, \sigma_l^{(i)})$ 为低通可学习高斯核， $\mu_l^{(i)}$ 、 $\sigma_l^{(i)}$ 为可学习的截止频率与带宽参数。直接乘以高斯核保证核函数在低频区域响应趋近于 1、高频区域响应趋近于 0，匹配低通滤波的频率特性。

得到高通和低通滤波器连续且可学习的频率掩码 $L_i(u, v)$ 和 $H_i(u, v)$ 后，可以通过门控信号进行调整和过滤。门控网络接收启发式特征 S 后，通过 Softmax 函数生成各专家的路由分配权重 $g_{L,i}$ 与 $g_{H,i}$ 。随后，模块将这些掩码广播至所有通道，并与原始频域特征 $F(u, v)$ 进行逐元素相乘调制。整个多专家动态协同过滤的过程可表示为：

$$M'(u, v) = \sum_{i=1}^3 (g_{L,i} \cdot (M(u, v) \odot L_i(u, v)) + g_{H,i} \cdot (M(u, v) \odot H_i(u, v))) \quad (1.25)$$

网络保留了对当前场景最有利的频率分量，并抑制了无用的冗余频段。完成频域过滤后，特征通过二维逆傅里叶变换（2D-IFFT）重构回空间域，并经过反归一化得到 M_{iff} 。为了弥补频域截断可能造成的细微空间特征丢失，重构后的特征进一步输入卷积残差模块。卷积残差模块由多个交替的Conv-ReLU块组成，最终通过残差连接输出解码特征 M_{out} 。

启发式频域选择解码器的核心优势在于，它通过低通专家分支自适应地滤除了这些高频噪声，为分类头提供了极其纯净平滑的特征。在高频分段，它通过高通专家分支动态保留了由先验与空间对齐模块共同构建的真实物体边缘高频信号，为定位头提供了丰富的细节特征。分头头和定位头的增强一起显著提升了模型在复杂开放场景下的检测上限。

损失函数

基于 SAM2 先验引导与空频域对齐的目标检测模型的总体损失函数 L_{total} 定义如下：

$$L_{total} = \lambda_{cls} L_{cls} + \lambda_{reg} L_{reg} + \lambda_{distill} L_{distill} \quad (1.26)$$

其中 L_{cls} 为目标分类损失， L_{reg} 为边界框回归损失， $L_{distill}$ 为特征蒸馏损失。 λ_{cls} 、 $\lambda_{distill}$ 与 λ_{reg} 为超参数平衡系数，用于动态调节分类、定位和蒸馏在反向传播过程中的梯度贡献占比，以确保模型在多任务学习下的稳定收敛。

特征蒸馏损失采用基于均方误差的特征蒸馏损失。该损失函数用于约束轻量级代理生成器输出的特征 $S_{student}^{(c,h,w)}$ 逼近冻结的 SAM2 编码器提取的高质量边界先验 $S_{SAM2}^{(c,h,w)}$ 。其具体定义如下：

$$L_{distill} = \frac{1}{C \times H \times W} \sum_{c,h,w} \left(S_{student}^{(c,h,w)} - S_{SAM2}^{(c,h,w)} \right)^2 \quad (1.27)$$

分类损失采用焦点损失^[24]作为分类分支的优化目标。其数学表达如下：

$$L_{cls} = - \sum_{i=1}^N [y_i \alpha (1-p_i)^\gamma \log(p_i) + (1-y_i)(1-\alpha) p_i^\gamma \log(1-p_i)] \quad (1.28)$$

其中 N 表示样本总数； $y_i \in 0,1$ 为第 i 个样本的真实类别标签（GroundTruth）； p_i 为网络预测该样本属于正类的概率。 α 为平衡正负样本权重的因子， γ 为聚焦参数（FocusingParameter），用于降低易分样本的权重，使网络将注意力集中在难分样本上。

边界框回归损失采用 CIoU 损失作为回归分支的优化目标。CIoU 综合考虑了边界框的重叠面积、中心点距离以及长宽比（AspectRatio）的一致性，能够为网络提供更全面的几何尺度约束。CIoU 损失的具体定义如下：

$$L_{\text{reg}} = 1 - \text{CIoU} = 1 - \left(\text{IoU} - \frac{\rho^2(b, b^{\text{gt}})}{c^2} - \alpha_v \cdot v \right) \quad (1.29)$$

其中 b 和 b^{gt} 分别代表预测框和真实框的中心点坐标， $\rho(\cdot)$ 表示计算两点之间的欧几里得距离； c 代表能够同时包含预测框和真实框的最小闭包区域的对角线距离。 v 是用于度量长宽比一致性的参数， α_v 是对应的权重函数，其计算公式分别为：

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan \frac{w}{h} \right)^2 \quad (1.30)$$

$$\alpha_v = \frac{v}{(1 - \text{IoU}) + v} \quad (1.31)$$

其中 w, h 和 $w^{\text{gt}}, h^{\text{gt}}$ 分别表示预测框与真实框的宽度和高度。

实验结果和分析

实验准备

本章对比实验共设置 8 个模型，包括 FFCA、C2Former、YOLOFIV、CAFF-DINO、GM-DETR、M-SDETR、DPAL-P 和 MS2Fusion 多种代表性公开方法。这些模型覆盖单阶段检测、基于 Transformer 的端到端检测以及跨模态特征对齐与融合等不同技术路线，能够从检测精度、特征表达能力和实时性三个层面构成较为完整的横向对比。其中，YOLOFIV 可作为速度基线，C2Former、GM-DETR、M-SDETR 和 CAFF-DINO 可反映基于注意力机制与全局建模的检测性能，DPAL-P 与 MS2Fusion 则可用于分析显式对齐和多层融合设计的实际收益。

实验数据集选取 VEDAI、M3FD、FLIR 和 DroneVehicle。上述四个数据集分别覆盖遥感俯视场景、地面交通场景、自动驾驶夜间感知场景以及无人机多高度监视场景，能够较好反映复杂光照、尺度变化、遮挡和小目标密集分布等问题。为保证比较公平，若数据集提供公开划分，则直接采用官方或公开常用划分；若无统一测试划分，则在固定随机种子 42 下按类别分布进行分层划分，确保训练集、验证集与测试集在目标类别和场景分布上保持一致。本章算法所采用的数据集划分设置如表 3.1 所示。

表 3.1 数据集划分设置

数据集	应用场景	划分方式	训练/验证/测试
VEDAI	遥感俯视车辆检测	按 8:1:1 划分	968/121/121

M3FD	道路场景 RGB-T 检测	按 4:1:1 划分	2800/700/700
FLIR	交通场景对齐三类检测	官方 Train/Val/Test 划分	7976/886/1366
DroneVehicle	无人机多光谱车辆检测	官方 Train/Val/Test 划分	16960/1887/1887

软硬件环境方面，实验在单卡 GPU 服务器上完成，并配合 NumPy、OpenCV 与 MMEEngine 等常用工具完成训练和评测。统一的运行环境有助于减小由框架版本、驱动差异和算子实现带来的性能波动，使不同模型之间的比较更具有可重复性和可信度。本章算法所采用的软硬件环境如表 3.2 所示。

表 3.2 软硬件环境

名称	版本
操作系统	Ubuntu20.04
处理器	IntelXeonSilver4310
内存	128GB
Python	3.10
PyTorch	2.1.2
CUDA	11.8
GPU	NVIDIAGeForceRTX4090

训练策略上，优先采用各对比模型公开实现中的推荐权重初始化方式，骨干网络加载 ImageNet 或 COCO 预训练参数，新增融合模块与检测头采用随机初始化。为保证公平性，除模型原论文有强制设置外，实验尽可能统一输入分辨率为 640×512 ，批大小设置为 8，总训练轮次为 100 轮。优化器采用 AdamW，初始学习率设为 1×10^{-4} ，权重衰减系数为 5×10^{-4} ，前 5 轮使用线性 warm-up，随后采用余弦退火策略衰减学习率。数据增强方面，训练阶段对可见光与红外图像同步执行随机水平翻转、随机缩放、随机裁剪和多尺度缩放，以保持跨模态空间对应关系。针对可见光分支额外使用亮度、对比度和色彩抖动，以增强模

型对复杂光照变化的鲁棒性。评价时统一在相同置信度阈值和 NMS 设置下进行，以避免不同后处理策略对结果造成额外干扰。

数据集介绍

VEDAI^[55]是一个专门用于航拍多光谱图像中车辆目标检测的大型公开数据集，广泛应用于遥感图像分析和目标识别领域。该数据集由卫星或者高空飞行器拍摄而成，包含了大量相同场景下的可见光与近红外图像对。VEDAI 的主要特点是图像覆盖的地理范围广、背景环境极其复杂多样，且目标尺寸普遍较小。数据集原始包含超过 1200 对图像，通常被裁剪为 512×512 或 1024×1024 像素的固定尺寸。其标注类别极其精细，主要涵盖了多种交通工具，如轿车、卡车、船舶、拖拉机、露营车等。由于是从高空俯视拍摄，目标不具备丰富的纹理细节，仅表现出极其微弱的轮廓特征。因此，如何在这种低分辨率、小目标密集、背景严重干扰的场景下，充分融合可见光丰富的颜色纹理和红外图像对热源敏感的优势，是 VEDAI 数据集带给跨模态目标检测模型的核心挑战。对于基于 DETR 架构的模型而言，捕捉全局上下文并聚焦于微小目标特征尤为关键。

M3FD 是近期由科研机构发布的一个高质量跨模态基准数据集，主要面向图像融合与目标检测的双重任务。相较于传统数据集，M3FD 的图像分辨率更高，且不同模态间的空间对齐极其精确，几乎消除了因为配准误差带来的检测干扰。该数据集总共包含 4200 对严格配准的可见光和热红外图像对，应用场景聚焦于真实的城市街道与日常环境。其标注涵盖了六个常见的目标类别：People、Car、Bus、Motorcycle、Lamp、Truck。更重要的是，M3FD 极大地丰富了环境光照的多样性，不仅包含光线充足的白天场景，还包含了大量具有挑战性的场景，如光照极度匮乏的黑夜、光照不均的黄昏、以及被云雾遮挡的阴天。在这些复杂场景下，可见光图像经常会失效，而红外图像虽然能凸显热源目标，却缺乏场景几何结构。这

种高度互补性使得 M3FD 成为检验跨模态特征融合算法能否在极端光照条件下保持高鲁棒性的测试平台。

FLIR 数据集是由全球著名的热成像技术公司针对高级辅助驾驶系统和自动驾驶领域发布的跨模态公开数据集。它记录了从车载视角出发的城市交通场景，目的是推动基于热成像技术的自动驾驶安全性研究。数据集包含了从不同城市、白天和夜间驾驶环境中采集的超过 14000 对注释良好的热红外与可见光图像对。图像默认分辨率为 640×512 。为了适应自动驾驶的迫切需求，本文实验采用的是跨模态检测研究中常用的对齐三类子集：Person、Bicycle、Car。由于采集设备的物理空间位置差异，FLIR 数据集中的可见光和红外图像往往存在一定程度的视差。这种模态间的空间不对齐，对基于 Transformer 架构的检测模型的特征对齐和融合能力提出了极其严苛的考验。模型必须学会在存在少量位置偏差的特征图中准确提取并关联同一目标的跨模态语义。

DroneVehicle 数据集是针对无人机视角专门构建的大规模双模态车辆检测数据集，为无人机夜间巡航、交通监控和灾害救援提供了重要的数据支撑。由于是从低空无人机拍摄，视角呈现出大角度倾斜甚至垂直俯视的特点。该数据集规模庞大，共收集了约两万对可见光和红外图像对，并且图像分辨率较高。它包含了海量的车辆目标实例，标注涵盖了 5 类机动车辆：Car、Truck、Bus、Van、Freight car。与自动驾驶视角不同，无人机视角的图像呈现出极端的尺度变化、高密度的目标排布以及目标具有任意方向的旋转特性。这要求目标检测模型不仅要解决跨模态信息互补的问题，还必须克服目标旋转和密集遮挡带来的边界框回归难题。DroneVehicle 深刻地体现了多光谱信息融合在航空检测领域的巨大价值。

评价指标

目标检测模型评价指标体系为全面评估模型在检测精度与推理实时性之间的平衡性能，本文选取 mAP50、mAP50:95、精确率（Precision）、召回率（Recall）与每秒帧率（FramesPerSecond,FPS）作为核心评价指标，所有指标均以“↑”标识数值越大模型性能越优。

mAP 系列指标与目标检测框的定位匹配程度直接相关，因此首先引入交并比（Intersection over Union, IoU）作为检测结果有效性的核心判定依据，其计算表达式为：

$$\text{IoU} = \frac{|B_p \cap B_g|}{|B_p \cup B_g|} \quad (1.32)$$

式中， B_p 为模型输出的预测框， B_g 为数据集标注的真实框。IoU 取值越大，代表预测框与真实框的空间重叠度越高；当 IoU 达到预设阈值时，该预测结果判定为有效检测。

基于 IoU 的有效检测判定规则，精确率 Precision 与召回率 Recall 的定义如下：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \times 100\% \quad (1.33)$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \times 100\% \quad (1.34)$$

式中，TP（TruePositive）为真正例数量，即被正确检测的目标数量；FP（FalsePositive）为假正例数量，即误检的目标数量；FN（FalseNegative）为假负例数量，即漏检的目标数量。精确率用于表征模型预测结果中有效检测的占比，数值越高代表模型误检率越低；召回率用于表征数据集中真实目标被成功检出的占比，数值越高代表模型漏检率越低。

为综合量化模型在不同召回率水平下的全局检测性能，本文引入平均精度（Average Precision, AP），并对所有类别的 AP 取均值得到平均精度均值。对于第 c 个目标类别，其 AP 定义为精确率-召回率（P-R）曲线下的积分面积，表达式为：

$$\text{AP}_c = \int_0^1 P_c(R) dR \quad (1.35)$$

式中， $P_c(R)$ 为第 c 类目标在召回率为 R 时对应的精确率。

在此基础上，mAP50 指 IoU 阈值固定为 0.50 时，所有类别 AP 的算术平均值；mAP50:95 指在 IoU 阈值区间 [0.50, 0.95] 内、以 0.05 为步长的 10 组阈值下，所有类别 AP 的全局平均值，该指标对目标定位精度的要求更为严苛，可更全面地表征模型的综合检测性能。二者的计算表达式分别为：

$$\text{mAP@50} = \frac{1}{C} \sum_{c=1}^C \text{AP}_c |_{\text{IoU}=0.50} \times 100\% \quad (1.36)$$

$$\text{mAP@50:95} = \frac{1}{10C} \sum_{t \in 0.50:0.05:0.95} \sum_{c=1}^C \text{AP}_c |_{\text{IoU}=t} \times 100\% \quad (1.37)$$

式中， C 为检测任务的目标类别总数。相较而言，mAP50 更侧重评估模型在宽松匹配条件下的目标检出能力，而 mAP50:95 对目标框的定位精度要求更高，更适用于复杂场景下模型综合检测质量的量化评估。

除上述检测精度指标外，本文采用每秒帧率 FPS 量化模型的推理效率，其定义为模型单位时间内可完成推理的图像帧数，表达式为：

$$\text{FPS} = \frac{N_{\text{frame}}}{T} \quad (1.38)$$

式中， N_{frame} 为完成推理的图像总帧数， T 为对应推理过程的总耗时。FPS 数值越高，代表模型的实时推理能力越强，更适配对响应速度有严格要求的工程落地场景。

综上，mAP50 与 mAP50:95 主要用于量化模型的检测精度与定位性能，精确率与召回率分别表征模型的误检与漏检水平，FPS 则用于评估模型的实时推理能力。后续实验将基于上述指标开展对比分析，实现对不同模型的检测准确性、鲁棒性与工程落地可用性的系统评估。

实验分析

为客观且全面地评估本文所提出的基于 SAM2 先验引导与空频域对齐的目标检测算法在复杂跨模态检测任务中的实际效能，本节将在 VEDAI、M3FD、FLIR 以及 DroneVehicle 四个极具挑战性的公开数据集上开展详尽的对比实验。为了彰显本文算法的竞争优势，实验选取了当前多模态领域内最具代表性的 8 种前沿网络作为对比基线，具体涵盖 FFCA、C2Former、YOLOFIV、CAFF-DINO、GM-DETR、M-SDETR、DPAL-P 和 MS2Fusion。后续论证过程将严格划分为定量测定与定性评估两大核心维度。在定量测定方面，实验将依托 mAP50、mAP50:95、精确率（Precision）、召回率（Recall）以及推理帧率（FPS）等严谨的评价指标体系，系统性地比对各模型在特征解耦精度、边界框回归准度及工程实时性上的各项量化差异。在定性评估环节，本节将通过大量直观的可视化检测结果图，深度剖析不同网络在应对红外热噪干扰、传感器物理视差错位、极暗退化环境以及无人机高空视角等极端长尾场景时的表现，从而多层次、多方位地证实本文算法在克服三重不对齐方面的卓越鲁棒性与先进性。

（1）VEDAI 数据集实验结果定性和定量分析

为了更直观地展现本文模型在极端场景下解决三重不对齐问题的实际效果，图 3.5 展示了基于 SAM2 先验引导与空频域对齐的目标检测算法与 8 种前沿对比算法在 VEDAI 航空遥感数据集上的检测结果可视化对比。该场景极具挑战性：不仅拍摄视角极高导致目标，如汽

车、卡车等像素占比微小，且右上方建筑区域存在目标密集停放，其余目标则散落并严重伪装在与自身颜色极度相似的复杂泥土背景中。如图中左侧泥土道路及中心空地上的孤立微小车辆所示，由于目标颜色与背景几乎融为一体，FFCA、C2Former 甚至表现较好的YOLOFIV 均出现了明显的漏检现象。这是因为传统的特征提取器在面对弱纹理背景时，容易陷入模态竞争，导致特征提取失败。而本文的基于 SAM2 先验引导与空频域对齐的目标检测算法成功检测出了这些隐藏目标。这主要归功于由融合 RGB-IR 输入经 SAM2 Image Encoder 蒸馏得到的边界轮廓先验，以及通道-网格细粒度解耦编码器。即便在复杂背景和微小目标场景下，该边界轮廓先验仍可与通道级红外显著响应形成互补，从而提供更稳定的目标边界参考。在图像右上角的建筑和集装箱旁，停放了多辆极其密集的小型车辆。观察可知，CAFF-DINO 和 MS2Fusion 等模型在该区域不仅出现了部分误检，如将背景建筑特征误认为车辆，且其生成的边界框（BoundingBox）存在明显的漂移，无法紧密包围目标。这是因为航空双目相机微小的物理视差在深层特征中被放大，产生了边缘重影与高频插值伪影。反观本文的基于 SAM2 先验引导与空频域对齐的目标检测算法，图 3.5 右下角，其生成的预测框不仅没有错漏，而且异常精准、严丝合缝地贴合了每一个微小目标的轮廓。这印证了本文聚焦-发散动态空间对齐机制在亚像素级别消除视差错位的有效性。



图 3.5 VEDAI 数据各模型检测结果对比

如表 3.3 所示，本文提出的基于 SAM2 先验引导与空频域对齐的目标检测算法在 VEDAI 数据集上取得了 90.8% 的 mAP50，相较于次优模型 GM-DETR 提升了 4.6%。更值得注意的是，在更为严苛的 mAP50:95 指标上，本文模型达到了 65.4%，展现出了断层式的优势。这主要归功于本文设计的启发式频域选择解码器（HFSD）。传统的融合模型，如 MS2Fusion、C2Former 在处理极小目标时，融合带来的高频伪影极易破坏边界框回归的精度；而本文模型通过高通专家精确保留了真实物体的边缘高频跳变，使得边界框在极高 IoU 阈值下依然能够精准贴合目标轮廓。在精确率和召回率方面，本文模型分别达到了 92.1% 和 91.5%。部分基线模型，如 DPAL-P、YOLOFIV 存在较为严重的误检或漏检，这主要是由于无人机高空视角下传感器视差造成的‘边缘重影’干扰了网络的分类判断。本文通过引入聚焦-发散动态空间对齐机制，在亚像素级别将错位特征重新拉扯对齐，从源头上消除了多模态特征不匹配带来的语义混淆，从而实现了 P 和 R 的双向且均衡的提升。在推理效率（FPS）的综合评估中，基于单阶段密集预测架构的 YOLOFIV 取得了最快的推理速度（76FPS），但其

各项精度指标均出现显著落后。值得注意的是，由于 VEDAI 数据集存在大量密集的航空微小目标，YOLOFIV 在后处理阶段执行非极大值抑制（NMS）的计算开销急剧增加，导致其帧率相比常规场景有所下降。反观基于 Transformer 架构的模型，如 C2Former 为 31FPS，GM-DETR 仅为 24FPS，全局自注意力机制的高昂计算代价导致其徘徊在实时性边缘。本文模型在保持最高检测精度的同时，取得了高达 64FPS 的高实时推理速度，仅略低于极简的 YOLOFIV。这充分验证了本文架构的高效性：在推理阶段完全卸载大模型（SAM2）教师分支，依托轻量级的 MoE 路由与频域过滤机制，成功避免了复杂的跨模态空间计算冗余，实现了精度与速度的绝佳平衡，完全满足航空遥感平台对高频采样的严苛要求。

表 3.3VEDAI 数据集评价指标

（最优指标结果以黑色粗体标出）

模型名称	mAP ₅₀ (%)↑	mAP _{50:95} (%)↑	Precision(%)↑	Recall(%)↑	FPS↑
FFCA	74.8	45.6	76.3	75.1	50
C2Former	75.7	48.5	77.2	76.8	31
YOLOFIV	80.1	51.8	81.5	79.4	76
CAFF-DINO	74.1	49.2	75.8	73.5	29
GM-DETR	86.2	59.1	87.4	86.8	24
M-SDETR	82.2	54.6	83.1	82.7	30
DPAL-P	83.4	55.9	84.6	83.9	46
MS2Fusion	84.2	56.8	85.3	85.1	41
Ours	90.8	65.4	92.1	91.5	64

（2） M3FD 数据集实验结果定性和定量分析

图 3.6 展示了各对比模型在 M3FD 数据集中一个极具挑战性的真实车载场景，雨天叠加迎面车辆强光眩光下的检测结果。在该场景中，RGB 可见光图像因左前方车辆的强光直射产生了大面积的高亮眩光与路面反光倒影，导致该区域的目标视觉特征被严重掩盖；而 IR 红外图像虽然不受眩光影响，但受雨水降温作用，远处的行人及车辆热辐射特征显得极其微弱且边缘模糊。这种双模态局部退化极其考验模型的抗干扰与特征互补能力。首先，在强眩光区域的抗干扰能力上，传统融合模型，如 FFCA、YOLOFIV、甚至较新的 MS2Fusion 受到 RGB 图像中车灯光晕和路面高亮倒影的严重误导。这些模型在强光中心或反光路面上产生了错误的边界框，或者未能准确标定出眩光背后的真实车辆轮廓。相比之下，本文的基于 SAM2 先验引导与空频域对齐的目标检测算法能够穿透强光干扰，精准地框选出对面驶来的车辆。这表明：当 RGB 模态在强光区发生严重特征退化时，门控机制能够动态掐断受损的

可见光信号，强制引入该区域轮廓清晰的红外特征作为补全，从而从根本上避免了被强光致盲的现象。其次，在弱热辐射目标的精准捕捉上，请注意画面最左侧路边的行人，在 IR 图中仅表现为极其微弱的亮斑。部分基于全局注意力的模型，如 CAFF-DINO 和 GM-DETR 在处理这一区域时，因红外特征过弱且伴随雨雾高频噪声，出现了漏检，未能检测出行人。而本文模型不仅成功捕获了该行人，且其预测框的尺度与 GT 极为吻合。这一优势归功于本文的启发式频域选择解码器（HFSD）。该模块通过低通专家分支自适应地过滤了雨滴与复杂路面的高频环境噪声，保障了分类分支对微弱行人特征的敏锐感知。




图 3.6M3FD 数据各模型检测结果对比

由表 3.4 可知，在面临黑夜、雨雾及强光眩光等极其复杂的 M3FD 场景中，部分基于常规融合策略的模型如 FFCA、YOLOFIV 性能出现了大幅衰减，mAP50 仅维持在 54%左右。这是由于在极端光照下，可见光特征严重退化，传统的双流拼接引发了负面的模态竞争。而本文提出的基于 SAM2 先验引导与空频域对齐的目标检测算法依然取得了 73.3%的最优 mAP50，这充分证明了本文模型的价值。当 RGB 模态在夜间或眩光下失效时，门控机制能够自适应地将高质量的红外对齐特征作为额外信息强行注入特征金字塔，确保了深层语义信息的连贯性，从而在 Recall（75.4%）上实现了对漏检目标的有效挽回。值得深入探讨的是，侧重于空间对齐的 DPAL-P 模型在 mAP50（72.4%）上展现出了极强的竞争力，与本文模型差距较小。然而，在要求更为严苛的边界框回归指标 mAP50:95 上，本文模型

（52.6%）相较于 DPAL-P（48.2%）拉开了 4.4% 的显著代差。这一现象的物理本质在于：M3FD 数据集中充斥着雨雾模糊与红外背景热噪，DPAL-P 仅在空间域进行对齐，无法显式剥离这些高频干扰，导致边界框定位发生微小偏移；而本文模型通过启发式频域选择解码器（HFSD），利用全局频谱特征动态生成任务掩码，让高通专家精准锁定真实的物理边缘，彻底消除了伪影干扰，从而在极高 IoU 阈值下依然保持了卓越的定位精度。在推理帧率（FPS）方面，由于 M3FD 属于常规的街景目标密度分布，后处理计算负担较轻，各基于 CNN 的融合模型的推理速度相较于密集高空场景均有明显回升。本文模型在引入频域变换与多尺度特征对齐的情况下，依然达到了 74FPS，推理效率紧追最快的 YOLOFIV（86FPS），且远超 DPAL-P（54FPS）等空间域对齐模型。这进一步印证了本文离线先验蒸馏架构的工程优越性：无论光照场景如何突变，轻量级路由器凭单次前向传播即可完成复杂的特征动态分发，在提供卓越抗干扰能力的同时，仅增加了极微小的在线推理延迟。

表 3.4M3FD 数据集评价指标
（最优指标结果以黑色粗体标出）

模型名称	mAP ₅₀ (%)↑	mAP _{50:95} (%)↑	Precision(%)↑	Recall(%)↑	FPS↑
FFCA	53.6	31.2	56.1	55.2	58
C2Former	58.3	37.1	60.5	59.3	34
YOLOFIV	54.4	33.5	58.2	54.8	86
CAFF-DINO	55.5	34.8	57.6	56.5	31
GM-DETR	57.7	36.2	59.4	58.9	26
M-SDETR	66.4	43.5	68.8	67.6	33
DPAL-P	72.4	48.2	74.5	73.8	54
MS2Fusion	61.7	39.4	64.1	63.5	48
Ours	73.3	52.6	76.2	75.4	74

（3） FLIR 数据集实验结果定性和定量分析

图 3.7 展示了各对比模型在 FLIR 车载数据集中的白天城市桥梁路段检测结果。该场景的挑战并不在于极度恶劣的光照，而在于中远距离路段上存在的多目标密集停放与相互遮挡，并且由于车载可见光与热成像双目相机的物理基线设计，目标在 RGB 与 IR 图像的特征融合时极易产生横向视差错位。首先，在克服传感器视差与抑制边界框漂移方面，如图左侧那辆体积较大的白色 SUV。FFCA、C2Former 等缺乏显式空间纠偏机制的传统模型，在融合存在位移差异的 RGB 纹理与 IR 热源时，深受边缘重影的干扰，导致其预测框显得过于宽泛。而本文提出的基于 SAM2 先验引导与空频域对齐的目标检测算法通过聚焦-发散动态空

间对齐机制，利用空洞卷积扩大感受野感知视差，在亚像素级别将发生偏移的特征强行“拉扯”至同一空间坐标系内，从而彻底消除了重影，实现了严丝合缝的回归定位。其次，在应对中远距离密集遮挡目标的召回率方面，画面正前方的远端密集车流有多辆车相互部分遮挡。在这一高难度区域，YOLOFIV、CAFF-DINO 以及 GM-DETR 等多种先进网络均出现了明显的误检，如标框为一个整体或严重的漏检。相比之下，本文模型基于 SAM2 先验引导与空频域对齐的目标检测算法却能极其清晰、独立地为每一辆密集遮挡的小车生成精确的预测框。这一优异表现直接得益于本文的 SAM2 先验驱动的网络级特征解耦编码器：在特征提取初期，网络专家在 SAM2 边界轮廓先验的引导下，对每一个独立目标的局部轮廓保持了极高的敏感度，防止了特征在深层网络中被粘连或同化，配合后续的启发式频域过滤，成功剥离了密集区域的冗余融合噪声，使得模型在处理这种高密度遮挡场景时展现出了较好的分辨能力。




图 3.7FLIR 数据各模型检测结果对比

如表 3.5 所示，在车载 FLIR 数据集上，传统仅依赖通道拼接或注意力融合模型，如 YOLOFIV、FFCA、CAFF-DINO 性能普遍陷入瓶颈，mAP50 停滞在 72% 左右。其根本原因在于，FLIR 数据集的可见光与红外相机之间存在不可忽视的物理基线视差，未配准的特征直接融合会导致严重的边缘重影现象，极大干扰了网络的学习。而本文提出的基于 SAM2

先验引导与空频域对齐的目标检测算法以 83.5%的 mAP50 和 85.6%的 Precision 领先。这强有力地证明了本文设计的聚焦-发散动态空间对齐机制的有效性。通过多尺度空洞卷积感知的发散度，该机制成功构建了距离反比的重采样场，在特征融合前实现了亚像素级别的动态纠偏，彻底清除了重影带来的虚警，从而在 Precision 指标上取得了显著突破。在 FLIR 数据集上，同样具备对齐功能的 DPAL-P 模型表现出了强劲的实力，mAP50 达到 82.4%。然而，在严苛的定位指标 mAP50:95 上，本文模型 53.8%以 3.1%的优势超越了 DPAL-P50.7%。这种领先揭示了空间域对齐的局限性：DPAL-P 仅在空间域通过可变形卷积进行拉扯，这种强制重采样往往伴随着高频插值伪影的产生。本文模型通过后续的启发式频域选择解码器（HFSD），利用动态掩码在频域内抑制了这些重采样伪影，使得最终输出给检测头的特征边缘既几何准确又纯净无噪，实现了较高的边界框精准贴合度。面向 FLIR 数据集典型的自动驾驶车载应用场景，算法的推理时延直接关乎智能系统的安全响应极限。尽管 GM-DETR、M-SDETR 以及 C2Former 等基于 Transformer 的模型在多目标精度上有所建树，但其徘徊在 25~35FPS 左右的帧率在面对高速行驶场景时仍显捉襟见肘。相比之下，本文模型不仅在多项精度指标上取得绝对领先，更通过特征解耦机制，最终实现了 76FPS 的高流畅度处理帧率。这种以极微小的时间损耗，换取大幅定位精度提升的设计，这展现了本模型较高的工程落地价值。

表 3.5FLIR 数据集评价指标

（最优指标结果以黑色粗体标出）

模型名称	mAP ₅₀ (%)↑	mAP _{50:95} (%)↑	Precision(%)↑	Recall(%)↑	FPS↑
FFCA	71.5	42.1	74.8	72.3	59
C2Former	72.3	43.5	75.2	73.1	35
YOLOFIV	69.3	40.8	71.6	70.4	88
CAFF-DINO	71.7	42.6	74.5	72.8	32
GM-DETR	72.2	43.1	75.0	73.4	27
M-SDETR	80.0	48.9	81.3	80.5	34
DPAL-P	82.4	50.7	83.2	82.8	56
MS2Fusion	75.9	45.4	77.8	76.6	49
Ours	83.5	53.8	85.6	84.3	76

（4） DroneVehicle 数据集实验结果定性和定量分析

图 3.8 展示了各对比模型在 DroneVehicle 无人机高空俯视数据集中的夜间十字路口场景检测结果。该场景汇集了多重极端挑战：首先，RGB 图像中两辆汽车的远光灯产生了极其

强烈的光束与高频光晕，导致局部区域发生严重的视觉致盲。其次，无人机极高的拍摄视角使得目标极其微小。更严苛的是，在画面最左侧的黑暗边缘，存在两辆几乎完全被截断的微小黑色车辆，见 GT 图最左侧的蓝色标注框，其视觉与热辐射特征均极其微弱。首先，在抵抗强烈光晕致盲与高频噪声干扰方面，FFCA、YOLOFIV 等传统模型在处理画面中央强光束照射区域时，其预测框由于受到光晕边缘特征的误导，出现了明显的尺度膨胀或定位偏移。而本文的基于 SAM2 先验引导与空频域对齐的目标检测算法预测框却能无视强光束的干扰，紧密贴合真实的车辆轮廓。这一优异表现直接证实了本文启发式频域选择解码器（HFSD）的降噪保本能力。通过低通专家在频域内过滤掉车灯造成的高频光晕噪声，同时结合聚焦-发散动态对齐模块在光盲区动态注入红外通道的有效特征，网络成功避免了光照突变对目标定位的破坏。其次，在极限边缘残缺微小目标的召回能力上，观察画面最左侧黑暗边缘处的两辆截断汽车可以发现：由于特征面积过小且缺乏完整的物理轮廓，C2Former、CAFF-DINO、GM-DETR 等几乎所有基线模型均在此处发生了严重的漏检。相比之下，唯有本文的基于 SAM2 先验引导与空频域对齐的目标检测算法能够敏锐地捕捉并精确框选出这两个濒临丢失的目标。这种极高召回率的背后，是本文大模型驱动的网络级特征解耦编码器在发挥决定性作用。在特征提取初期，SPD-DRE 在特征提取初期能够在由融合 RGB-IR 输入经 SAM2 Image Encoder 蒸馏得到的边界轮廓先验引导下，更好地聚焦边缘局部的微弱角点与残缺轮廓，防止了微小特征在深层网络中被大面积的夜间背景语义所淹没。




图 3.8DroneVehicle 数据各模型检测结果对比

如表 3.6 所示，DroneVehicle 数据集因其极高的无人机拍摄视角，目标呈现出极端的微小化与密集化特征。传统模型（如 FFCA、C2Former）在此场景下 Recall 指标大幅下跌，普遍在 70%左右徘徊，说明其存在严重的漏检问题。相比之下，表现强劲的 YOLOFIV 与 CAFF-DINO 将 mAP50 提升至 81%以上。而本文提出的基于 SAM2 先验引导与空频域对齐的目标检测算法以 82.3%的 mAP50 和 83.6%的超高 Recall 登顶。这一突破主要得益于本文的网格级特征解耦模块。在特征提取阶段，网格专家敏锐捕捉了微小目标的局部轮廓；在融合阶段，即使某波段的高空特征发生衰减，模态补全机制亦能强制注入高优信号，确保了微弱语义在金字塔深层的连续传递，从根本上缓解了高空小目标的漏检难题。DroneVehicle 包含大量城市夜间场景，充斥着霓虹灯光晕干扰与无人机红外传感器的强烈热背景噪声。这些噪声极易导致边界框定位漂移，这也是为何大多数基线模型在 mAP50:95 指标上表现乏力，如 YOLOFIV 仅为 50.1%的原因。本文模型在 mAP50:95 上达到了 54.2%，拉开了近 3%的显著优势。这归功于启发式频域选择解码器。面对城市夜景复杂的全局频谱，HFSD 动态生成的低通掩码如同一个‘智能滤镜’，彻底洗净了高频光晕与热噪干扰，确保了回归头仅仅依赖真实物体的物理边缘进行框选，在极限 IoU 阈值下依然展现出了卓越的定位精度。对于受限于极低功耗与边缘算力的无人机视觉系统而言，算法的推理效率面临着极为严苛的挑战。特

别是在 DroneVehicle 数据集中，极高的无人机俯视视角导致画面中充斥着海量的密集小目标。这种极端的拥挤度急剧增加了传统 CNN 融合模型在执行非极大值抑制（NMS）时的计算负担，导致 YOLOFIV 的帧率大幅滑落至 63FPS，FFCA 降至 43FPS。面对这一计算压力极大的极端场景，本文算法不仅在各项严苛的精度指标上全面压制了现有先进模型，更凭借高效的频域解码机制与轻量化架构，在目标极度密集的情况下依然守住了 53FPS 的高实时性底线，证明了本架构在极端长尾拥挤场景下不仅算得准，而且算得快。

表 3.6DroneVehicle 数据集评价指标
(最优指标结果以黑色粗体标出)

模型名称	mAP ₅₀ (%)↑	mAP _{50:95} (%)↑	Precision(%)↑	Recall(%)↑	FPS↑
FFCA	71.6	41.2	74.3	70.8	43
C2Former	71.5	40.9	74.5	70.1	29
YOLOFIV	81.0	50.1	82.2	80.6	63
CAFF-DINO	81.6	51.5	83.1	81.2	26
GM-DETR	76.9	45.8	78.4	76.2	22
M-SDETR	74.9	44.2	77.2	73.8	28
DPAL-P	79.8	48.6	81.6	79.5	40
MS2Fusion	77.9	46.5	80.3	77.1	36
Ours	82.3	54.2	84.5	83.6	53

消融实验

为了深入探究本文提出的模型中各个创新模块对整体检测性能的具体贡献，本节在存在显著传感器视差的 FLIR 数据集，如表 3.7 所示，与侧重高空微小目标的 DroneVehicle 数据集，如表 3.8 所示，上开展了严谨的消融实验。实验以逐一剥离核心模块的方式进行，全面评估了 SAM2 先验引导的细粒度解耦路由编码器（SPD-DRE）、聚焦-发散动态空间对齐机制（F-DDSA）以及启发式频域选择解码器（HFSD）三个组件在不同物理场景下的作用机制。

观察表 3.7 和表 3.8 的第一行数据可知，当完全移除 SPD-DRE 模块时，即网络退化为缺乏先验指导的普通并行提取，模型性能出现了最严重的断崖式下跌。在 FLIR 数据集上，mAP50 暴跌 3.0%；在 DroneVehicle 数据集上，mAP50 下降 2.0%，且召回率（Recall）同样锐减 2.0%。这一结果说明了在缺乏由融合 RGB-IR 输入经 SAM2 Image Encoder 蒸馏得到的边界轮廓先

验，以及通道、网格细粒度解耦机制约束时，网络极易陷入跨模态特征的语义混淆，特别是面对高空微弱残缺目标时，极易发生严重的特征丢失与漏检现象。

对比表中的第二行与第四行数据，F-DDSA 模块缺失带来的负面影响在 FLIR 数据集上体现得尤为明显。剥离该模块后，FLIR 数据集上的 mAP50 从 83.5%降至 82.1%，更值得注意的是精确率（Precision）下降了 0.9%。这种查准率的流失，从物理层面反映了在面对双目相机固有的庞大物理视差时，缺乏亚像素级引力纠偏机制，导致未对齐的特征被生硬拼接，直接引发了严重的边界重影，导致模型产生了大量的虚警。该模块的引入消除了空间几何错位，保障了检测框的纯净度。

对比表中第三行数据，可以得出虽然模型依然具备对齐机制，但在最为严苛的回归定位指标 mAP50:95 上均遭遇了显著下滑。在 FLIR 上，mAP50:95 下降 1.2%；在 DroneVehicle 上更是跌 1.0%。这表明无论是跨模态特征的重采样过程，还是无人机夜间传感器的固有属性，都不可避免地伴随着高频热噪与插值伪影。缺乏 HFSD 的动态频域过滤，这些冗余噪声被直接送入回归头，干扰了边界框对真实物理轮廓的精细贴合。实验数据强有力地证明了 HFSD 成功实现了从粗略框选向像素级精准定位的跨越。

综上所述，本文提出的三个核心模块在特征解耦提取、空间视差纠偏与频域去噪过滤方面各自发挥了不可替代的作用，三者紧密耦合且高度互补。

表 3.7 消融实验在 FLIR 数据集上的性能指标对比

（最优指标结果以黑色粗体标出）

SPD-DRE	F-DDSA	HFSD	mAP ₅₀ (%)↑	mAP _{50:95} (%)↑	Precision(%)	Recall(%)
	√	√	80.5	51.1	83.2	82.8
√		√	82.1	52.6	84.7	83.5
√	√		82.6	52.6	84.7	83.9
√	√	√	83.5	53.8	85.6	84.3

表 3.8 消融实验在 DroneVehicle 数据集上的性能指标对比

（最优指标结果以黑色粗体标出）

SPD-DRE	F-DDSA	HFSD	mAP ₅₀ (%)↑	mAP _{50:95} (%)↑	Precision(%)	Recall(%)
	√	√	80.3	52.2	82.5	81.6

√		√	81.9	53.2	84.1	82.7
√	√		81.4	53.2	83.8	82.8
√	√	√	82.3	54.2	84.5	83.6

本章小结

本章针对跨模态检测中的提取竞争、空间视差与频域冗余三重痛点，提出了一种基于 SAM2 先验引导与空频域对齐的目标检测算法。首先，详细介绍了通过引入 SAM2 模型先验蒸馏实现通道-网格的高质量解耦提取，构建聚焦-发散机制消除亚像素级空间错位，并设计启发式频域解码器滤除冗余噪声，实现了从特征到任务的严格对齐。其次，介绍了模型训练的硬件平台、数据集、评价指标和对比的算法，确保了实验的可重复性。最后，通过多数据集对比与消融实验充分验证了本模型在复杂环境下的较强的检测性能。